

DeltaFold — Plan d’expérimentation (état actuel)

Clustering structural non supervisé du virome par apprentissage topologique

Matthieu Nardi — stage M2

June 25, 2026

Document de travail. Il fixe les *questions* auxquelles la prochaine campagne doit répondre, puis le dispositif (données, objectif, architecture, métriques, témoins, portes de décision) conçu pour y répondre. Il fait suite au post-mortem de la première run, qui n’apprenait rien au-delà du signal des features.

Contents

1	But et cadrage	1
2	Les questions auxquelles le plan doit répondre	1
3	Post-mortem de la première run (motivation)	2
4	Dispositif expérimental	2
4.1	Données	2
4.2	Objectif refondu (trois composants)	2
4.3	Architecture et ablations	3
5	Métriques	3
6	Baselines et témoins	3
7	Correspondance question → test → critère	4
8	Portes de décision (falsifiables)	4
9	Risques principaux	4

1 But et cadrage

But scientifique. Reproduire, puis si possible étendre, l’étude de Nomburg et al. (2024) sur le virome : recouvrer une organisation structurale des protéines virales et, à terme, proposer de nouveaux analogues structuraux pour les protéines « sombres » (sans homologue connu). L’outil est un encodeur structural appris sur le complexe combinatoire de la protéine (hiérarchie résidu → élément de structure secondaire → protéine).

Décisions actées.

- **Non supervisé pur** : on retire le contrastif supervisé (positifs « même cluster Foldseek ») et le terme auxiliaire TM-score, pour éliminer toute fuite côté entraînement.
- **Architecture équivariante** (SE(3)), de type perceptron géométrique, consommant les vecteurs de déplacement $C\alpha$ et non plus seulement des scalaires invariants.
- **Objectif refondu** (voir §4) : positifs par sous-structures, file de négatifs, tête de projection.
- **Base de prototypage corrigée** : représentative (avec singletons, distribution de tailles préservée), à distinguer du jeu complet.

2 Les questions auxquelles le plan doit répondre

Q1 — Apport de la hiérarchie topologique. Les complexes combinatoires (hiérarchie résidu/SSE/protéine) encodent-ils quelque chose que les recherches structurales actuelles (Foldseek, embeddings globaux) ne capturent pas, en particulier l'*homologie partielle / de domaine* ?

Q2 — Objectif et création des paires. Quelle stratégie de positifs et quel objectif permettent un *apprentissage réel*, alors que la première run dégradait le signal des features au fil de l'entraînement ?

Q3 — Collapse. Comment éviter l'effondrement de la représentation observé en première run (sur les configurations à négatifs durs) ?

Q4 — Circularité de l'évaluation. Comment évaluer la qualité sans circularité vis-à-vis de Foldseek (qui est à la fois l'outil à battre et la « vérité terrain ») ?

Q5 — Géométrie : invariance vs équivariance. L'équivariance et la complétude géométrique apportent-elles, par rapport à un encodeur invariant scalaire ?

Q6 — Représentativité des données. La base de prototypage est-elle représentative, et les résultats transfèrent-ils au jeu complet ?

Q7 — Découverte (Nomburg). Peut-on retrouver les résultats de Nomburg et proposer de nouveaux analogues dans la fraction « sombre » ?

3 Post-mortem de la première run (motivation)

Sur la base de prototypage, un balayage d'ablations a montré que, pour presque toutes les configurations, le meilleur TM- ρ est atteint à l'époch 1–2 puis se *dégrade*, pendant que la perte de validation baisse, et *aucune* configuration ne bat la baseline à poids aléatoires. Les runs « features/géométrie seules » sont parmi les meilleurs. Diagnostic : l'entraînement contrastif ne fait pas qu'échouer à apprendre, il *détruit* le signal structural présent dans les features d'entrée. Causes principales identifiées dans la revue de littérature :

1. **Positifs triviaux** : deux vues jitter/masquage de la protéine entière sont quasi identiques (perte par batch $\sim 10^{-5}$) ; le modèle apprend une invariance au bruit sans rapport avec la similarité de fold.
2. **Négatifs durs $\rightarrow$ faux négatifs et collapse** : les quatre runs en collapse utilisent tous le *hard-negative mining* ; tous les runs sans négatifs durs l'évitent et obtiennent les meilleurs scores.

3. **Architecture en aval du goulot** : un encodeur plus expressif ne peut rien extraire d'un signal d'entraînement dégénéré.

4 Dispositif expérimental

4.1 Données

Base de prototypage *corrigée* ($\sim 3\text{--}5\text{k}$ protéines) : conserver une part de singletons, préserver la distribution des tailles de clusters (échantillonnage proportionnel, pas « 2 par cluster »), retirer la sélection par mots-clés du jeu d'entraînement, et adopter un découpage train/val « froid » (par cluster structural) avec déduplication des quasi-doublons. Re-run sur le jeu complet exigé avant toute conclusion biologique.

4.2 Objectif refondu (trois composants)

- **Positifs par sous-structures** (Hermosilla & Ropinski) : pour chaque protéine, deux sous-structures connexes *distinctes* (segment contigu par défaut ; boule spatiale en option). La taille est l'hyperparamètre critique (« sweet spot » : ni vues identiques, ni vues ne partageant plus le fold).
- **File de négatifs (MoCo)** : encodeur *online* + encodeur *momentum* (moyenne mobile, sans gradient) + file FIFO de clés négatives, ce qui découple le nombre de négatifs de la taille du batch. On *retire* le hard-negative mining.
- **Tête de projection** : la perte opère sur la projection ; l'embedding d'*évaluation* est pris *avant* la tête (jetée), ce qui prévient le collapse dimensionnel.

4.3 Architecture et ablations

Encodeur équivariant sur le complexe combinatoire. Ablations, un facteur à la fois :

Axe	Conditions	Question visée
Hiérarchie	PCC complet vs $-\text{rang } 2$ vs $-\text{rang } 3$ (plat) vs GNN plat	Q1
Géométrie	invariant scalaire vs GVP (norme) vs GCP (repères)	Q5
Objectif	avec/sans tête ; MoCo vs sans négatifs (VICReg/Barlow)	Q2, Q3
Positifs	taille de sous-structure ; contigu vs spatial	Q2
Encodage distance	sinusoïdal vs RBF	—

5 Métriques

- **Santé / collapse (porte bloquante)** : écart-type d'embedding, cosinus moyen hors-diagonale, rang effectif, alignement & uniformité.
- **Accord structural sans clustering** : TM-recall@ k et corrélation distance-TM contre une vérité **TM-align** (et non Foldseek).

- **Clustering vs références indépendantes** : ARI, V-measure, homogénéité/complétude, Fowlkes–Mallows contre **CATH** (Foldseek en simple sanity check) ; indices de fragmentation/fusion.
- **Spécifique hiérarchie** : récupération d’homologie *partielle* là où les méthodes globales échouent ; delta d’ablation des rangs.
- **Cohérence fonctionnelle (externe)** : pureté des clusters vis-à-vis EC/GO/Pfam.
- **Découverte** : nombre d’analogues « sombres » confiants (avec contrôle de FDR) ; contrôles positifs de Nomburg (RNA ligase T).

6 Baselines et témoins

Plancher : embedding aléatoire, modèle non entraîné. À comparer : Foldseek (global et local), méthodes d’embedding (FoldExplorer, TM-Vec), GNN plat (GearNet, GVP), décomposition en domaines + Foldseek, U-Nets géométriques. Témoins : permutation des clusters (null pour le supervisé), embedding mélangé.

7 Correspondance question → test → critère

Q	Test / dispositif	Critère de décision
Q1	Ablation des rangs + test d’homologie partielle vs baselines forts	Le PCC complet bat –rang 2 / plat / (domaines+Foldseek) sur l’homologie partielle, sinon la hiérarchie n’apporte rien
Q2	Positifs par sous-structures + MoCo + tête ; suivi loss/TM	Loss par batch non triviale <i>et</i> TM-rho/recall montent avec l’entraînement (au lieu de dégrader)
Q3	Tête de projection + file MoCo (repli VI-CReg/Barlow)	Rang effectif stable, cosinus moyen bas
Q4	Évaluation vs CATH, TM-align continu, fonction (EC/GO/Pfam)	Accord avec des références <i>indépendantes</i> de Foldseek, au-delà d’une distillation
Q5	Échelle invariant < GVP < GCP	Le gain géométrique justifie le coût
Q6	Base corrigée + re-run jeu complet	Les conclusions tiennent hors prototypage
Q7	Encoder viral + non-viral, retrieval multi-échelle, FDR	Reproduit les cas Nomburg ; analogues sombres sous seuil de FDR

8 Portes de décision (falsifiables)

1. **Tâche non triviale** : si la perte par batch s’effondre ($\sim 10^{-5}$), réduire la taille des sous-structures.
2. **Apprentissage réel** : si TM-rho/recall ne s’améliorent pas avec l’entraînement, l’objectif est encore mal posé.
3. **Non-circularité** : si l’accord avec CATH/fonction n’excède pas une distillation de Foldseek, pas de contribution démontrée.
4. **Hiérarchie** : si le PCC complet n’apporte rien sur l’homologie partielle, pivoter ou publier le résultat négatif.

9 Risques principaux

Mémoire (deux encodeurs équivariants sur 16 Go) ; réglage de la taille des sous-structures (nouveau point de défaillance) ; couverture CATH/fonction faible pour le virome (d'où TM-align continu en complément) ; collapse persistant (repli sur un objectif sans négatifs).